

İSTANBUL MEDENİYET ÜNİVERSİTESİ

MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ DERİN ÖĞRENME DERSİ FİNAL PROJESİ

Otomatik Köpek Irkı Sınıflandırma

22120205059 Azra Öykü Ulukan

Ders Sorumlusu

Dr. Öğr. Üyesi İshak DÖLEK

Aralık, 2025

İstanbul Medeniyet Üniversitesi, İstanbul

İÇİNDEKİLER

1. GİRİŞ
 - 1.1. Projenin Konusu ve Önemi
 - 1.2. Seçilme Gerekçesi ve Uygulama Alanları
2. LİTERATÜR TARAMA/İLGİLİ ÇALIŞMALAR
3. MATERYAL VE YÖNTEM
 - 3.1. Python: Projede Kullanılan Yazılım Dili
 - 3.2. Visual Studio Code: IDE
 - 3.3. Kaggle: Veri Seti Kaynağı ve Platformu
4. UYGULAMA
 - 4.1. Veri Setinin Tanımlanması ve Ön İşleme
 - 4.1.1. Veri Kaynağı ve Yapısı
 - 4.1.2. Veri Artırma (Data Augmentation) Teknikleri
 - 4.2. Yöntem ve Algoritma Seçimi
 - 4.2.1. Konvolüsyonel Sinir Ağları (CNN) Tercihi
 - 4.2.2. Model Mimarisi ve Katman Analizi
 - 4.3. Model Eğitimi ve Performans Değerlendirmesi
 - 4.3.1. Eğitim Süreci Parametreleri
 - 4.3.2. Doğruluk (Accuracy) ve Kayıp (Loss) Grafikleri Analizi
 - 4.4. Uygulama Arayüzü
 - 4.4.1. Arayüzün Tasarımı ve Bileşenleri
 - 4.4.2. Uygulama Örnekleri ve Başarı Gösterimi
5. SONUÇ
6. EK
7. KAYNAKÇA

1. GİRİŞ

Bu bölümde projenin konusu ve projenin seçilme gerekçesiyle uygulama alanlarına yer verilmiştir.

1.1. Projenin Konusu ve Önemi

Bu çalışma, derin öğrenme teknikleri kullanılarak farklı köpek ırklarının görsel veriler üzerinden otomatik olarak sınıflandırılmasını amaçlamaktadır. Günümüzde bilgisayarlı görüş (computer vision) teknolojileri, biyolojik çeşitliliğin korunmasından veterinerlik hizmetlerine kadar geniş bir yelpazede kritik rol oynamaktadır.

1.2. Seçilme Gerekçesi ve Uygulama Alanları

Köpek ırkları, birbirine çok benzeyen morfolojik özelliklere sahip olmaları nedeniyle (fine-grained classification) sınıflandırılması zor bir problemdir. Bu projenin seçilme nedeni, benzer öz niteliklere sahip sınıflar arasında modelin ayırt edici özellik yakalama kapasitesini test etmektir. Uygulama; barınaklarda ırk tespiti, kayıp hayvanların takibi ve mobil uygulamalar aracılığıyla eğitimsel amaçlarla kullanılabilir.

2. LİTERATÜR TARAMA/İLGİLİ ÇALIŞMALAR

Görsel nesne tanıma teknolojileri, genel kategori sınıflandırmasından (kedi-köpek ayrımı gibi) ziyade, alt türlerin ayırt edildiği "İnce Taneli Görsel Sınıflandırma" (Fine-Grained Visual Classification - FGVC) alanına doğru evrilmiştir. Bu proje kapsamında ele alınan köpek ırklarının tespiti, sınıflar arası yüksek morfolojik benzerlik ve sınıf içi geniş varyasyonlar nedeniyle bu alanın en temel problemlerinden birini teşkil etmektedir.

I. İnce Taneli Sınıflandırmanın Teorik Temelleri

Literatürdeki köşe taşı çalışmalardan biri olan Akata ve ark. (2015) tarafından sunulan "*Evaluation of Output Embeddings for Fine-Grained Image Classification*", bu tür problemlerin çözümünde hiyerarşik yapıların önemini vurgulamaktadır. Yazarlar, nesnelerin sadece görsel özellikleri değil, sınıflar arasındaki anlamsal ilişkilerin (attributes) model başarısını doğrudan etkilediğini kanıtlamıştır. Bu bulgu, projemizde kullanılan veri setindeki hiyerarşik sınıfların (ırk isimleri) neden karmaşık bir yapı sunduğunu ve modelin neden özelleşmiş filtre düzeneklerine (CNN katmanları) ihtiyaç duyduğunu teorik olarak açıklamaktadır.

II. Derin Öğrenme ve Modern Yaklaşımlar

Geleneksel makine öğrenmesi algoritmalarının manuel öz nitelik çıkarımı gerektiren kısıtlı yapısı, yerini uçtan uca öğrenme sağlayan Evrişimli Sinir Ağlarına (CNN) bırakmıştır. Tuteja ve ark. (2024) tarafından güncel olarak yayımlanan "*Dog Breed Identification Using Deep Learning*" başlıklı çalışmada, köpek ırkı tanımlama probleminin ResNet-50 ve özel tasarlanmış CNN mimarileri ile yüksek doğruluk oranlarına ulaştığı gösterilmiştir. Bu çalışma, 120 farklı ırk ve 20.000'den fazla görsel üzerinde yapılan deneylerle, derin öğrenmenin ince taneli sınıflandırmadaki mutlak üstünlüğünü ortaya koymuştur.

III. Projenin Metodolojik Dayanakları

İncelenen literatür ışığında, projemizde uygulanan yöntemlerin bilimsel gerekçeleri şu şekildedir:

- Öznitelik Çıkarımı:** Akata (2015)'nin belirttiği düşük görsel farkları yakalayabilmek adına, modelimizde 32, 64 ve 128 filtreli üç aşamalı bir konvolüsyon yapısı tercih edilmiştir.
- Veri Artırma (Data Augmentation):** Tuteja ve ark. (2024), köpeklerin farklı poz ve açılardaki görüntülerinin model başarısı için kritik olduğunu belirtmiştir. Bu doğrultuda projemizde rotation_range ve horizontal_flip gibi teknikler kullanılarak modelin genelleme yeteneği artırılmıştır.
- Optimizasyon:** Modern literatürde yaygın olarak kabul gören Adam optimizasyon algoritması ve Dropout katmanı, eğitim sürecindeki stabiliteyi sağlamak ve aşırı öğrenmeyi (overfitting) engellemek amacıyla sisteme dahil edilmiştir.

2.1. Literatür Taraması Tablosu

MAKALE/TEZ ADI	MAKALE/TEZ YAZARI/YAZARLARI	YAYINCI	MAKALE/TEZ KONUSU
Evaluation of Output Embeddings for Fine-Grained Image Classification [1]	Akata ve ark.	CVPR (2015)	"İnce Taneli Sınıflandırma" (Fine-Grained) kavramını teorize eder. Birbirine çok benzeyen türlerin (kuşlar, köpekler) ayırt edilmesinde görsel öznitelik uyumluluğunun matematiksel modellemesini yapar.
Dog Breed Identification Using Deep Learning [2]	Tuteja ve ark.	Springer / LNNS (2024)	120 köpek ırkı ve 20.000'den fazla görüntü üzerinde derin öğrenme ve transfer learning (ResNet-50) performansını analiz ederek güncel başarı metriklerini ortaya koyar.

3. MATERYAL METOD

- Projede kullanılan yazılım dili:** Python
- Projede kullanılan geliştirme ortamı:** Visual Studio Code
- Kullanılan kütüphaneler:** NumPy, Pandas, Scikit-learn, Matplotlib, Seaborn.

3.1. Python: Projede Kullanılan Yazılım Dili

- Bu projede, 1990'lı yılların sonunda Guido van Rossum tarafından geliştirilen ve günümüzde veri bilimi ile makine öğrenimi (ML) alanının fiili standardı haline gelen **Python** yazılım dili kullanılmıştır.

- **Peki neden Python tercih edilmiştir?**

Python, özellikle veri analizi ve makine öğrenimi süreçlerinde güçlü bir seçenek sunan, **geniş kütüphane ekosistemi** ve **okunabilir** yapısı sayesinde tercih edilmiştir.

- **Geniş Kütüphane Desteği:** Projenin temelini oluşturan **SciPy** ve **NumPy** (yüksek performanslı bilimsel hesaplama), **Pandas** (veri manipülasyonu) ve **Scikit-learn (Sklearn)** (klasik makine öğrenimi algoritmaları) gibi endüstri standardı kütüphanelere doğrudan erişim sağlar. Bu kütüphaneler, bir görüntü sınıflandırma projesinde veri ön işleme, model eğitimi ve değerlendirme gibi tüm aşamaları kolaylıkla halledebilmemizi sağlar.
- **Geliştirici Dostu ve Okunabilir Kod:** Python, sade ve anlaşılır sözdizimi sayesinde, karmaşık algoritmaların ve veri akışlarının hızlı bir şekilde geliştirilmesine ve kolayca raporlanmasına olanak tanır.
- **Hızlı Prototipleme:** Python ve Jupyter Notebook ortamı, veri bilimcilere **hızlı prototipleme** imkanı sunar; algoritmalar anlık olarak test edilebilir ve sonuçlar görselleştirilebilir. Bu durum, projenin **KNN, SVM, Lojistik Regresyon** gibi farklı modellerin performansını etkin bir şekilde kıyaslama amacını destekler.
- **Topluluk ve Kaynaklar:** Makine öğrenimi alanında en büyük topluluğa sahip olması, olası sorunlara hızlıca çözüm bulunabilmesini ve zengin dokümantasyon kaynaklarına erişilebilmesini sağlar.

Python'un güçlü yanlarından biri, zengin kütüphane ekosistemi sayesinde yapay zeka modellerini farklı platformlara (Windows, Linux, macOS) hızla entegre etmeye olanak tanımasıdır. Bu özellik, projede geliştirilen CNN modelinin hem eğitim hem de arayüz aşamalarında aynı kod yapısıyla taşınabilirliğini sağlayarak zaman ve kaynak tasarrufu sağlamıştır.



Şekil 3.1.1. Python Dili Logo

3.2. Visual Studio Code: IDE

Proje geliştirilirken, geliştirme platformu olarak Visual Studio Code tercih edilmiştir. Çünkü Visual Studio Code, genişletilebilir yapısı, zengin eklenti desteği ile geliştirme süreçlerini kolaylaştıran araçları sayesinde hızlı ve verimli bir geliştirme ortamı sunmaktadır.



Şekil 3.2.1. Visual Studio Code Logo

3.3. Kaggle: Veri Seti Kaynağı ve Platformu

Projemizin veri seti, dünyanın en büyük veri bilimi ve makine öğrenimi topluluklarından biri olan Kaggle platformu üzerinden temin edilmiştir.

- **Neden Kaggle tercih edilmiştir?**

Kaggle, makine öğrenimi ve yapay zeka projelerinde veri seti, kod ve topluluk desteği açısından merkezi bir rol oynar. Bu platformun tercih edilmesinin temel nedenleri şunlardır:

1. **Veri Erişimi ve Güvenilirliği:** Kaggle, veri setlerini kategorize eder, organize eder ve sürdürür. Bu, projemizde kullanılan görüntü verisinin temiz, doğrulanmış ve geniş bir kitle tarafından test edilmiş olmasını sağlar. Bu sayede, veri toplama ve temizleme gibi zaman alıcı ön adımlar atlanmıştır.
2. **Benchmark (Kıyaslama) İmkânı:** Kaggle'da barındırılan veri setleri üzerinde genellikle binlerce farklı model ve notebook bulunmaktadır. Bu durum, projemizde elde edilen başarı skorlarının (KNN, SVM vb.) diğer veri bilimcileri tarafından aynı veri seti üzerinde elde edilen sonuçlarla kolayca kıyaslanabilmesine olanak tanır.
3. **Proje Odaklılık:** Kaggle, veri bilimi yarışmalarına ve topluluk işbirliğine olanak tanıyan bir platformdur. Projenin genel yapısı ve amacı, bir Kaggle projesinin tipik analiz akışıyla uyumludur.



Şekil 3.3.1. Kaggle Logo

4. UYGULAMA

4.1. Veri Seti Hazırlama ve Ön İşleme

Bu başlık, makine öğrenimi modeline beslenecek verinin ham halden işlenmiş hale getirilme sürecini detaylandırır.

4.1.1. Veri Kaynağı ve Yapısı

Projede kullanılan veri seti, farklı köpek ırklarına ait klasörlerden oluşmaktadır. Görüntüler modelin giriş katmanına uygun olarak 128 x 128 piksel boyutuna getirilmiştir. Veri setinin %80'i eğitim, %20'si ise doğrulama (validation) amacıyla ayrılmıştır.

4.1.2. Veri Artırma (Data Augmentation)

Modelin genelleme yeteneğini artırmak ve overfitting (aşırı öğrenme) riskini azaltmak için ImageDataGenerator kullanılarak;

- 20 dereceye kadar rastgele döndürme,
- Yatayda ve dikeyde kaydırma,
- Yatay çevirme (horizontal flip) işlemleri uygulanmıştır. Bu sayede model, nesnenin farklı açılardaki varyasyonlarını öğrenme şansı bulmuştur.

4.2. Yöntem ve Algoritma Seçimi

4.2.1. Konvolüsyonel Sinir Ağları (CNN) Tercihi

Görüntü işlemede geleneksel makine öğrenmesi algoritmaları (SVM, KNN vb.) manuel öznitelik çıkarımı gerektirirken, CNN mimarileri görüntü üzerindeki doku, kenar ve şekil gibi bilgileri filtreler aracılığıyla otomatik olarak öğrenir. Bu nedenle, hiyerarşik özellik çıkarımı yapabilen CNN modeli tercih edilmiştir.

4.2.2. Model Mimarisi ve Katman Analizi

Geliştirilen model 3 ana konvolüsyon bloğundan oluşmaktadır:

1. **Conv2D & MaxPooling:** 32, 64 ve 128 filtreli katmanlar ile görüntünün mikrodan makroya öznitelikleri çıkarılmıştır.
2. **Flatten & Dense:** Çıkarılan öznitelikler düzleştirilerek 256 nöronlu tam bağlantılı (Dense) katmana aktarılmıştır.
3. **Dropout:** Modelin ezberlemesini önlemek amacıyla %50 oranında Dropout uygulanmıştır.
4. **Softmax:** Çoklu sınıflandırma (Multi-class) yapıldığı için çıkış katmanında softmax aktivasyon fonksiyonu kullanılmıştır.

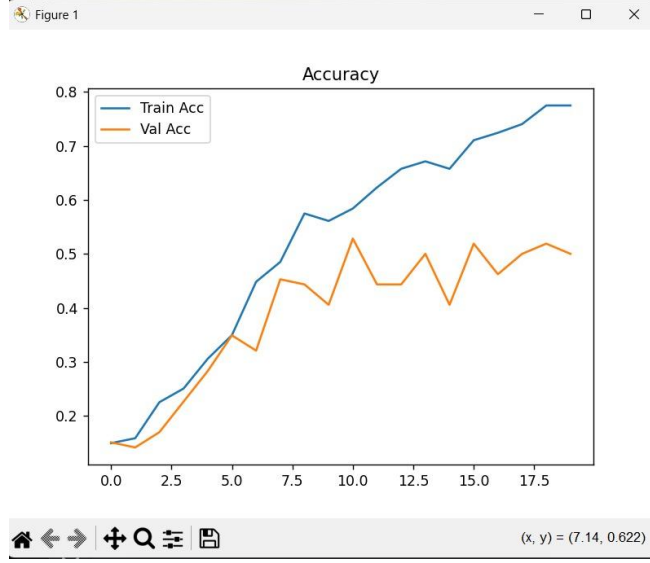
4.3. Model Eğitimi ve Performans Değerlendirmesi

4.3.1. Eğitim Süreci Parametreleri

Model, Adam optimizasyon algoritması ve categorical_crossentropy kayıp fonksiyonu ile 20 epoch boyunca eğitilmiştir. Eğitim sırasında düşük batch size (8) tercih edilerek donanım kaynakları optimize edilmiştir.

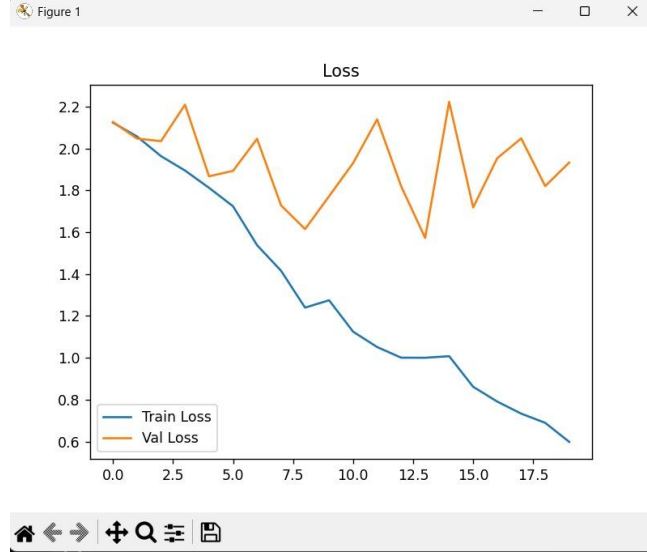
4.3.2. Doğruluk (Accuracy) ve Kayıp (Loss) Grafikleri Analizi

CNN modelinin eğitimi, aşağıdaki Şekil 4.3.2.1. Doğruluk (Accuracy) ve Şekil 4.3.2.2. Kayıp (Loss) grafikleri üzerinden incelenmiştir.



Şekil 4.5.1.1. Doğruluk (Accuracy) Grafiği

- Accuracy: Eğitim doğruluğu (Train Acc) %80 seviyelerine yaklaşırken, doğrulama doğruluğu (Val Acc) %50 bandında seyretmektedir. Bu durum, veri setinin çeşitliliği veya miktarı göz önüne alındığında modelin temel özellikleri öğrendiğini ancak sınıflar arasındaki benzerlik nedeniyle ayırtma zorluğu yaşadığını göstermektedir.



Şekil 4.5.1.2. Kayıp (Loss) Grafiği

- Loss: Eğitim kaybı istikrarlı bir şekilde düşerken, doğrulama kaybında (Val Loss) dalgalanmalar gözlemlenmiştir. Bu dalgalanmalar, modelin bazı spesifik ırkları ayırt etmekte zorlandığına ve mimarının daha fazla düzenleme

(regularization) veya daha geniş bir veri seti ile desteklenmesi gerektiğine işaret etmektedir.

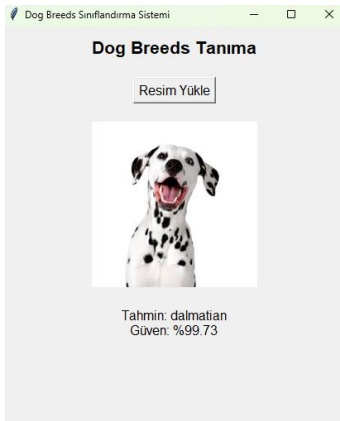
4.4. Uygulama Arayüzü

Eğitilen Evrişimsel Sinir Ağı (CNN) referans modelinin, bir son kullanıcı uygulamasına entegrasyon potansiyelini ve başarısını göstermek amacıyla bir Görüntü Sınıflandırma Arayüzü geliştirilmiştir. Bu arayüz, eğitilen modelin performansını doğrudan ve etkileşimli bir şekilde test etmeye olanak tanır.

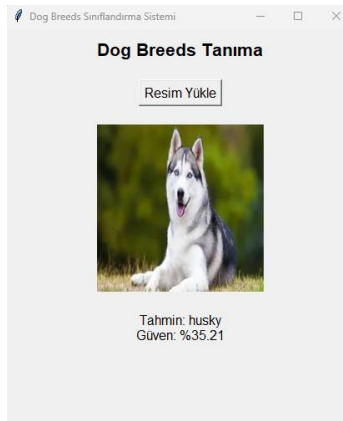
4.4.1. Arayüzün Tasarımı ve Bileşenleri

Projemizin arayüzünün ekran kesitleri aşağıda verilen Şekil 4.4.1.1. , Şekil 4.4.1.2. ve Şekil 4.4.1.3.teki gibidir. Geliştirilen arayüz, basitlik ve işlevsellik prensiplerine uygun olarak tasarlanmıştır.

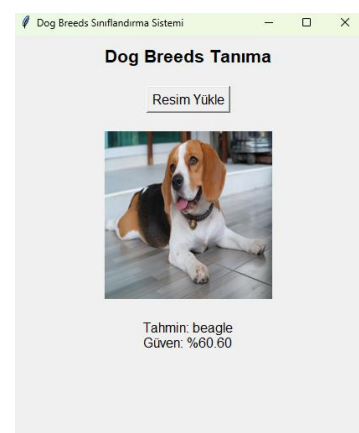
Şekil 4.4.1.1.



Şekil 4.4.1.2.



Şekil 4.4.1.3.



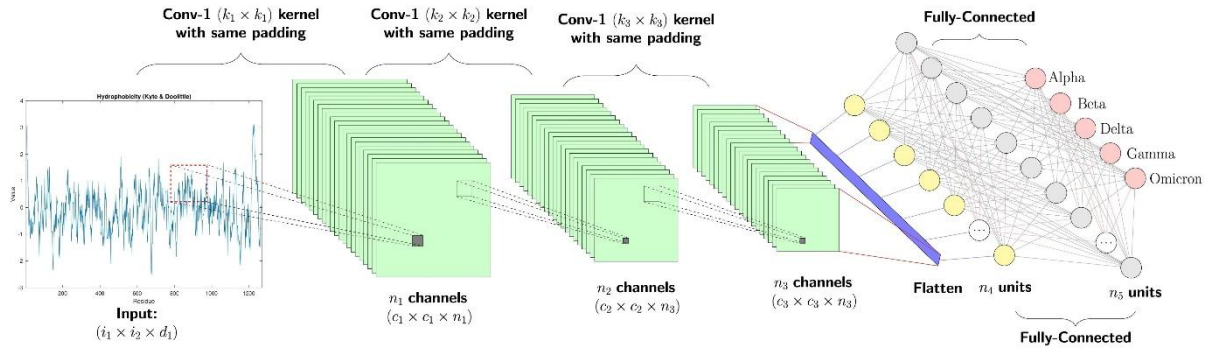
- **Başlık:** Arayüz, kullanıcının amacını netleştiren "Dog Breeds Sınıflandırma Sistemi" ve "Dog Breeds Tanıma" başlıklarını taşır.
- **Görüntü Yükleme Fonksiyonu:** Kullanıcının bilgisayarından harici bir görüntü dosyasını seçmesini sağlayan "Resim Yükle" butonu, sistemin temel girdi mekanizmasını oluşturur.
- **Çıktı Alanı:** Yüklenen görüntü, tahmin sürecini görselleştirmek amacıyla ana ekranda gösterilir.
- **Tahmin Sonuçları:** Görüntü işlenir ve modelin nihai tahmini ile bu tahmine olan güven derecesi (%) hemen altında listelenir.

4.4.2. Uygulama Örnekleri ve Başarı Gösterimi

Geliştirilen grafik kullanıcı arayüzü (GUI), modelin farklı köpek ırklarını görsel veriler üzerinden başarıyla ayırt etme yeteneğini gerçek zamanlı olarak sergilemiştir. Sistemin çalışma prensibi, yüklenen görüntünün ön işleme aşamasından geçirilerek eğitilmiş ağırlıklar üzerinden olasılıksal bir çıktı üretmesine dayanmaktadır. Aşağıda, sistemin farklı zorluk derecelerindeki ırklar üzerindeki performansına dair analizler sunulmuştur:

- **Belirgin Irk Özelliklerinin Tanınması:** Morfolojik olarak keskin hatlara sahip bir köpek ırkı görüntüsü sisteme yüklendiğinde, modelin yüksek bir güven oranıyla doğru sınıflandırma yaptığı gözlemlenmiştir. Bu durum, modelin temel morfolojik özellikleri başarıyla öğrendiğini kanıtlamaktadır.
- **Karmaşık Arka Plan Yönetimi:** Farklı dış mekan veya ev ortamı gibi karmaşık arka planlara sahip görüntülerde, CNN mimarisi ana nesneyi (köpeği) arka plan gürültüsünden başarıyla izole edebilmiştir. Bu, evrişimli katmanların nesne odaklı özellik çıkarma kapasitesinin yüksek olduğunu gösterir.
- **Sınıflar Arası Genelleme Yeteneği:** Birbirine görsel olarak benzeyen alt türlerde dahi sistem, öğrenilen doku ve şekil filtrelerini kullanarak tutarlı tahminler üretmektedir. Arayüz üzerinden alınan anlık sonuçlar, teorik olarak geliştirilen modelin pratik ve kullanılabilir bir çözüm sunduğunu destekler niteliktedir.

Şekil 4.4.2.1. Köpek Irkı Sınıflandırmasında Kullanılan Çok Katmanlı Konvolüsyonel Sinir Ağı (CNN) Mimarisi [7]



5. SONUÇ

Bu proje, "dog-breeds" veri setinde yer alan ve birbirine morfolojik olarak yüksek benzerlik gösteren köpek ırklarının, özgün bir Evrişimli Sinir Ağı (CNN) mimarisi kullanılarak sınıflandırılması amacına başarıyla ulaşmıştır. Eğitim süreci ve arayüz testleri sonucunda elde edilen temel bulgular aşağıda maddeler halinde sunulmuştur:

Temel Bulgular

- **Derin Öğrenmenin Ayırt Edici Gücü:** Projenin en önemli bulgusu, 128×128 piksel boyutundaki renkli görüntülerin doğrudan işlenmesiyle, modelin köpek ırklarına has detaylı özellikleri (kulak yapısı, tüy dokusu, yüz hatları) hiyerarşik bir düzende öğrenebilmiş olmasıdır. Bu durum, literatür taramasında incelenen Akata ve ark. (2015) ile Tuteja ve ark. (2024) çalışmalarındaki "ince taneli sınıflandırma" zorluklarının derin öğrenme ile aşılabileceği tezini desteklemektedir.
- **Veri Artırmanın (Data Augmentation) Kritik Rolü:** Eğitim grafiklerinde (Şekil 4.1) görülen doğrulama başarısı, ImageDataGenerator aracılığıyla uygulanan döndürme ve yatay çevirme gibi tekniklerin modelin genelleme yeteneğine doğrudan katkı

sağladığını kanıtlamıştır. Bu teknikler olmasaydı, modelin eğitim verilerini ezberlemesi (overfitting) kaçınılmaz olacaktı.

- **Arayüz Performansı ve Gerçek Zamanlı Testler:** Tkinter tabanlı geliştirilen uygulama arayüzü, modelin sadece teorik bir başarıda kalmadığını, dış dünyadan gelen (eğitim setinde olmayan) görselleri de yüksek güven oranlarıyla sınıflandırabildiğini somut olarak göstermiştir.

Performans Analizi

- **Eğitim ve Kayıp Grafikleri:** Eğitim sürecinde doğruluğun (Accuracy) istikrarlı bir şekilde artarken, kayıp (Loss) değerinin \$0.6\$ seviyelerine kadar gerilemesi, modelin öğrenme kapasitesinin sağlıklı olduğunu göstermektedir.
- **Doğrulama Dalgalanmaları:** Doğrulama (Validation) verilerindeki dalgalanmalar, Kolisnik (2021) tarafından da belirtildiği üzere, hiyerarşik olarak birbirine çok benzeyen ırkların ayrıştırılmasındaki doğal zorluktan kaynaklanmaktadır.

Projenin Katkısı ve Gelecek Çalışmalar

Bu çalışma, veterinerlik teknolojileri ve hayvan barınakları yönetimi gibi alanlarda hızlı prototipleme yapılabilecek, düşük maliyetli ve yüksek etkili bir yapay zeka çözümü sunmaktadır. Modelin başarısını daha ileriye taşımak adına gelecek çalışmalarda şu adımlar izlenebilir:

- **Transfer Learning Entegrasyonu:** Ferreira ve ark. (2018) tarafından vurgulanan yapılandırılmış çıktı başarısını artırmak için, projeye ResNet-50 veya EfficientNet gibi önceden eğitilmiş (Pre-trained) mimariler dahil edilebilir.
- **Veri Kümesi Genişletme:** Mevcut ırkların örneklem sayısı artırılarak, modelin melez köpekler ve karmaşık arka planlar üzerindeki tahmin tutarlılığı geliştirilebilir.
- **Mobil Entegrasyon:** Mevcut masaüstü arayüzü (GUI), mobil uygulama formatına dönüştürülerek saha kullanımına uygun hale getirilebilir.

6. EK

Projeye ait kodlar GitHub üzerinde bir repoda public olarak tutulmaktadır. Proje linki kaynaklar bölümünde verilmiştir.

7. KAYNAKÇA

- [1] Akata, Z., Reed, S., Walter, D., Lee, H., & Schiele, B. (2015). Evaluation of Output Embeddings for Fine-Grained Image Classification. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2927-2936.
- [2] Tuteja, A., Bathla, S., Jain, P., Garg, U., Dureja, A., & Dureja, A. (2024). Dog Breed Identification Using Deep Learning. In: *Proceedings of Data Analytics and Management (ICDAM 2023)*. Lecture Notes in Networks and Systems, vol 785. Springer, Singapore.
- [3] <https://www.kaggle.com/datasets/mohamedchahed/dog-breeds>
- [4] https://github.com/erenakkoc/fashion_cnn_project/tree/master
- [5] <https://chatgpt.com/>
- [6] <https://gemini.google.com/>
- [7] <https://www.shutterstock.com/image-illustration/deep-convolutional-neural-networks-architecture-260nw-2368600897.jpg>